

Projeto Final Integrador: Plataforma End-to-End de Engenharia, Governança e Analytics de Dados Ambientais

1. Visão Geral e Propósito do Projeto

O objetivo deste projeto é simular a construção de uma **plataforma corporativa moderna de dados** em uma empresa do setor ambiental e de saneamento. Os participantes atuarão no papel de **Engenheiros de Dados e Analistas Analytics**, sendo responsáveis por estruturar todo o ciclo de vida da informação: desde a captura de dados brutos de sensores e telemetria, passando pela limpeza, normalização, aplicação de regras de governança e segurança (LGPD), até a entrega final em um Data Lakehouse e dashboards executivos no Power BI.

O projeto integra todo o conhecimento adquirido ao longo do programa, garantindo que o aluno domine tanto a modelagem relacional tradicional quanto as arquiteturas modernas em nuvem e ferramentas de inteligência artificial aplicadas ao desenvolvimento.

2. Cenário de Negócio e Origem dos Dados

A empresa opera diversas **estações automáticas de monitoramento ambiental** distribuídas geograficamente em bacias hidrográficas e represas.

Cada estação possui sensores que realizam leituras temporais de parâmetros de qualidade da água e meteorologia, tais como:

- **Temperatura da Água e do Ar**
- **Potencial Hidrogeniônico (pH)**
- **Oxigênio Dissolvido (OD)**
- **Condutividade Elétrica**
- **Turbidez da Água**

Além das medições automáticas, existe o cadastro operacional de **Técnicos e Operadores de Campo** que realizam a manutenção e calibração periódica dos equipamentos. Os dados chegam de forma desestruturada ou semiestruturada via **APIs REST** e arquivos de lote (JSON / CSV), necessitando de tratamento antes de serem disponibilizados para análise.

3. Detalhamento dos Requisitos Módulo a Módulo

3.1 Ingestão e Consumo de APIs (Camada Bronze / Raw)

- **Consumo Resiliente de APIs:** O pipeline deve realizar requisições HTTP para buscar as leituras das estações. É obrigatório implementar tratamento de erros para queda de conexão, respostas vazias e controle de limite de requisições por minuto (*Rate Limiting*).
- **Validação Estrita de Contrato:** Antes de aceitar qualquer dado da API, o pipeline deve validar o formato recebido contra um **Data Contract**

(Contrato de Dados). Registros que não cumprirem o contrato (ex: campos obrigatórios ausentes ou tipos de dados incompatíveis) devem ser rejeitados e registrados em log de auditoria.

- **Persistência Bruta (Append-Only):** Os dados brutos aprovados devem ser armazenados na pasta **Bronze** do Data Lake em seu formato original (JSON), acompanhados de colunas de metadados de controle (data/hora da ingestão e nome da fonte).

3.2 Qualidade, Governança e Tratamento (Camada Silver / Cleansed)

- **Auditoria das 6 Dimensões da Qualidade de Dados:**
 1. *Completeness:* Tratar ou remover registros que possuam campos vitais nulos (ex: leitura sem identificação da estação ou sem data).
 2. *Unicidade:* Identificar e eliminar linhas duplicadas causadas por retransmissões da API ou falhas na rede.
 3. *Acurácia e Validade:* Filtrar inconsistências físicas (ex: valores de pH abaixo de 0 ou acima de 14, temperaturas fora de limites viáveis).
 4. *Tempestividade e Consistência:* Garantir que a ordenação temporal das leituras esteja correta.
- **Segurança e Conformidade com a LGPD:**
 - O cadastro de Operadores de Campo contém dados pessoais sensíveis (como CPF e Nome Completo).
 - É **obrigatório** aplicar técnicas de **Anonimização Irreversível via Hashing (SHA-256)** nas chaves de identificação pessoal e criptografia reversível para dados que exijam recuperação futura.
- **Persistência Otimizada na Silver:** Os dados limpos e governados devem ser gravados na pasta **Silver** do Data Lake no formato colunar **Parquet** com compressão Snappy.

3.3 Modelagem Relacional Tradicional (3ª Forma Normal - 3FN)

Além do armazenamento em arquivos no Data Lake, a equipe deve estruturar um **Banco de Dados Relacional Operacional**. O modelo relacional deve ser estritamente projetado na **3FN**, composto pelas seguintes tabelas:

1. **Estacoes (Tabela Cadastral):** Armazena os dados fixos de cada estação (Identificador, Nome da Estação, Município, Estado).
2. **Operadores (Tabela Cadastral):** Armazena as informações dos técnicos, com os campos de identificação pessoal devidamente anonimizados.
3. **Parametros (Tabela de Domínio):** Cadastro dos parâmetros medidos (Código do Parâmetro, Nome do Parâmetro, Unidade de Medida).

4. **Leituras (Tabela Transacional / Cabeçalho):** Registra o evento da leitura (Identificador do Pedido/Leitura, Data/Hora Exata, Chaves Estrangeiras para Estação e Operador).
5. **Leitura_Itens (Tabela Associativa N:M):** Detalha quais parâmetros foram medidos em cada leitura e seus respectivos valores observados, possuindo uma **Chave Primária Composta**.

3.4 Análise Estatística & Detecção de Outliers

O pipeline deve extrair os dados da camada Silver/SQL para realizar análises estatísticas automáticas:

- **Tendência Central:** Calcular Média e Mediana para cada parâmetro ambiental por estação.
- **Dispersão:** Calcular Desvio Padrão, Variância e Intervalo Interquartil (IQR).
- **Detecção Automática de Anomalias (Outliers):** Identificar leituras atípicas utilizando a regra do Amplitude Interquartil ($IQR = Q3 - Q1$) e validação por Z-Score. Leituras classificadas como anômalas devem ser sinalizadas com um indicador específico de alerta de qualidade.

3.5 Modelagem Dimensional e Curadoria (Camada Gold)

- **Arquitetura Star Schema (Esquema Estrela):** Transformar os dados da Silver em um modelo multidimensional otimizado para consultas analíticas de alta performance.
- **Estrutura de Tabelas na Gold:**
 - **Fato_Medicoes:** Tabela central que contém as métricas numéricas (Valor Lido, Média Móvel, Indicador de Outlier) e as Chaves Substitutas (*Surrogate Keys - SK*).
 - **Dim_Estacao:** Contexto geográfico das estações.
 - **Dim_Tempo:** Dimensão conformada com granularidade de Ano, Mês, Dia, Trimestre, Dia da Semana e Dia Útil.
 - **Dim_Parametro:** Detalhes operacionais das medições.

3.6 Visualização de Dados no Power BI

O modelo semântico da Camada Gold deve ser conectado ao Power BI para a criação de um Dashboard Executivo e Operacional:

- **Relacionamentos e Cardinalidades:** Configurar corretamente as ligações 1: N entre as Dimensões e a Fato.
- **Medidas em DAX:** Criar indicadores agregados usando funções essenciais como soma de medições, médias móveis temporais e filtros dinâmicos de status de qualidade.

- **Storytelling e Visualização:** Montar telas interativas contendo mapas geográficos das estações, cartões de indicadores de alerta, gráficos de tendência temporal e filtros por bacia/município.


3.7 Orquestração, Idempotência e CI/CD

- **Idempotência Garantida:** A reexecução de qualquer etapa do pipeline para uma data histórica (*Backfill*) deve obrigatoriamente sobrescrever a partição afetada sem gerar linhas duplicadas no banco relacional ou no Data Lake.
- **Logging Estruturado:** O pipeline não deve utilizar exibições simples de tela. Deve implementar um sistema de **Logs Estruturados** contendo carimbo de data/hora, nível de severidade (INFO, WARNING, ERROR) e mensagem descritiva.
- **Controle de Versão (Git Flow):** Todo o desenvolvimento deve ser versionado no Git. O trabalho em equipe deve utilizar ramificações lógicas (*branches* como *main*, *feature/ingestao*, *feature/modelagem*, *feature/analytics*) e as entregas feitas via *Pull Requests*.
- **Documentação e Runbook:** O repositório final deve conter um arquivo explicativo completo (README.md) detalhando a arquitetura da solução, o dicionário de dados, as instruções de instalação e o roteiro de execução operacional (*Runbook*).


4. Estrutura de Pastas Esperada no Repositório

O projeto entregue no GitHub deve estar organizado na seguinte estrutura modular:

Estrutura de Pastas do Repositório do Projeto Integrador Ambiental



5. Fluxo de Dados e Arquitetura do Processo



6. Critérios de Avaliação e Entregáveis Finais

Para considerar o projeto concluído com sucesso, a equipe deverá apresentar:

1. **Repositório Público ou Privado no GitHub:** Contendo o histórico legível de commits, divisão de tarefas por branches, testes unitários automatizados e documentação no README.md.
2. **Data Lakehouse Populado:** Comprovação da presença dos arquivos nas pastas bronze, silver e gold, demonstrando a evolução da qualidade dos dados ao longo das camadas.
3. **Banco de Dados Relacional (3FN):** Scripts SQL executados com sucesso, com restrições de Chaves Primárias, Estrangeiras e integridade referencial mantidas.
4. **Relatório Estatístico e de Qualidade:** Apresentação dos logs de execução comprovando a detecção de outliers e o descarte/tratamento de registros inconsistentes.
5. **Dashboard Interativo no Power BI:** Apresentação prática dos relatórios conectados à Camada Gold, demonstrando navegação fluida, filtros operacionais e storytelling focado em tomada de decisão.